

Nombre: Santiago Nicolás Jadán Mora

Asignatura: Inteligencia Artificial

Carrera: Biomedicina

La función de pérdida, conocida como Loss function en YOLOv8, es utilizada para evaluar la discrepancia entre las predicciones realizadas por la red neuronal y los valores reales de las observaciones durante el proceso de aprendizaje. Cuanto menor sea el resultado de esta función, más eficiente será la red neuronal en este caso, YOLOv8. Su propósito es minimizar la desviación entre los valores predichos y los valores reales para cada observación ajustando los pesos de la red neuronal.

En el contexto de imágenes biomédicas y respecto a las Convolutional Neural Networks (CNN), se emplean diversas funciones de pérdida según la tarea a realizar:

- Entropía cruzada (Cross-Entropy): Usada comúnmente en problemas de clasificación multi-clase. Mide la diferencia entre la distribución de probabilidad predicha por la red y la distribución real de las etiquetas de las imágenes.
- Dice Loss (F1 Loss o coeficiente de Dice): Utilizada en tareas de segmentación de imágenes, donde el objetivo es obtener máscaras de segmentación que representen regiones de interés en la imagen. El coeficiente de Dice mide la similitud entre las regiones segmentadas y las regiones de referencia.
- Mean Squared Error (MSE): Útil en problemas de regresión. En imágenes biomédicas, puede emplearse para estimar cantidades numéricas asociadas a la imagen, como el tamaño de una lesión.
- Binary Cross-Entropy: Utilizada específicamente en problemas de clasificación binaria, como detectar la presencia o ausencia de cierta característica o patología en una imagen.
- Weighted Losses (Pérdidas ponderadas): Se emplean para abordar el desbalance de clases en tareas de segmentación o clasificación, asignando pesos diferentes a las clases minoritarias o regiones de interés.

Las fortalezas de las Convolutional Neural Networks incluyen una mayor precisión en tareas con grandes cantidades de datos, eficiencia computacional debido al uso de convoluciones y extracción automática de características sin requerir ingeniería manual.

Sin embargo, también presentan debilidades, como la necesidad de grandes cantidades de datos para evitar el sobreajuste, la dificultad para interpretar y explicar sus decisiones debido a su complejidad y la limitada generalización a nuevos dominios.

Las CNN pueden aplicarse al dominio temporal porque pueden aprender y extraer características relevantes de datos secuenciales, lo que las hace útiles en tareas como procesamiento de señales de audio y análisis de series temporales.

Aunque teóricamente es posible utilizar SVM en el dominio temporal, su aplicación no es tan común o efectiva en comparación con otras técnicas más adecuadas, como las RNN y las CNN. Algunas de las razones incluyen que los SVM no toman en cuenta la estructura temporal de los datos, tienen dificultades con el tamaño variable de entrada en series temporales y pueden perder información temporal al trabajar con características independientes. Estas limitaciones hacen que las RNN y las CNN sean opciones más adecuadas para modelar datos temporales.

#### **REFERENCIAS:**

Pathak, A. (2022, agosto 30). Redes neuronales convolucionales (CNN): una introducción. Geekflare. <https://geekflare.com/es/convolutional-neural-networks/>

Las CNN mejoran el análisis de imágenes. (s/f). Softtek.com. Recuperado el 30 de julio de 2023, de <https://blog.softtek.com/es/las-cnn-mejoran-el-analisis-de-imagenes>

Vannieuwenhuyze, A. (2020). Inteligencia artificial fácil: machine learning y deep learning prácticos.